

Relatorio de mudanas no c3digo

Silvaneo Viera dos Santos Junior

5/19/2022

Reposit3rios dos c3digos

Reposit3rio das fun3es do pacote e da aplica33o do Shiny:

<https://github.com/silvaneojunior/GDLM>

Reposit3rio dos gr3ficos e an3lises produzidas com o c3digo:

https://github.com/silvaneojunior/Projeto_graduacao

O primeiro reposit3rio possui a vers3o est3vel mais recente dos c3digos, ademais, ele 3 restrito aos c3digos gerais, sem an3lises de dados. Este reposit3ria 3 atualizado regularmente conforme o desenvolvimento do pacote GDLM avança.

O segundo reposit3rio possui vers3es experimentais do c3digo (o caso normal, por exemplo) e vers3es antigas, ademais, os ajustes feitos para dados especificos se encontram nele. Eventualmente esse reposit3rio deixar3 de ser atualizado, permanecendo apenas como um registro do que foi feito.

Mudanas gerais (exceto caso Normal)

- Limpeza do c3digo: remo33o de vari3veis e coment3rios n3o utilizados.
- Simplifica33o do loop de filtragem: todo o processo definido em um loop (originalmente a primeira itera33o era executada fora do loop).
- Otimiza33o do loop de filtragem: minimiza33o de produtos matriciais e de chamadas de fun33es *gamma*, *digamma* e *trigamma*.
- Separa33o das fun33es de filtragem, predi333o, suaviza333o e ajuste.
- Otimiza33o do loop de suaviza333o: minimiza33o da quantidade de invers33es de matrizes.
- Inclus33o da possibilidade de vari3veis com vari3ncia nula: durante a suaviza333o, estas vari3veis s3o removidas das opera333es.
- Mudana na matriz R_t , inicialmente definida como $\frac{1}{\delta}P_t$, onde $P_t = GC_tG'$ e δ 3 o fator de desconto (n3o precisa ser escalar no c3digo, mas por simplicidade, escreverei como um escalar). Na vers3o atual, temos $R_t = \frac{1}{\delta}P_t + W_t$, onde W_t 3 uma matriz sim3trica definida n3o-negativa (falta incluir um erro para quando esta restri333o n3o 3 respeitada pelo usu3rio). A ideia dessa mudana veio da observa333o do fato de que, na especifica333o original, se $C_0 = 0$ (vari3ncia 3 priori), ent33o $C_t = 0$ para todo t . Com a inclus33o da matriz W_t , 3 poss3vel que uma vari3vel tenha vari3ncia 0 at3 um certo tempo e depois receba um choque aleat3ria.
- Adi333o da possibilidade de fatores de desconto distintos a cada tempo.
- Padroniza333es entre os c3digos para o caso Poisson (com Linear Bayes) e Multinomial.

Caso multinomial

- Generalização do código para k categorias (conforme o artigo no arxiv).
- Extensão da F_t para regressão dinâmica. No original, $F_t = F$ para todo t (série temporal).
- F_t se tornou um array de dimensão $n \times r \times T$ (n é o número de variáveis latentes, r é a quantidade de series na saída do modelo e T é o tempo final). Para cada tempo, temos uma matriz $n \times r$, sendo que o preditor linear está definido como $F'_t \theta_t$.
- F_t não é mais bloco diagonal, é possível definir variáveis latentes que tem efeito em mais de uma série. Desvantagem: um pouco mais complicado para o usuário fazer a especificação, porém algumas funções auxiliares foram criadas para facilitar o processo, além disso, a aplicação do *Shiny* simplifica o processo.
- Generalização da condição inicial para o Newton-Raphson (garantindo inicialização válida): $\vec{x}_{inicial} = (0.01, \dots, 0.01, 0.01 \times r)$. Essa inicialização garante que $x_{r+1} - \sum_{i=1}^r x_i > 0$ (x_{r+1} está associado ao total de ocorrências).

Caso Normal

Esse script recebeu o mínimo de alterações necessárias para que o ajuste funcionasse, de modo a evitar introduzir erros antes que resolver os que já estavam presentes

- Correções gerais para igualar o código e as equações do artigo (as mudanças já tinham sido quase integralmente observadas pela Mariane anteriormente).
- Mudança de variáveis do sistema de compatibilização da priori: o sistema passa a ser escrito em termos de $\mu_0 = -\frac{\tau_2}{\tau_1}$, $c_0 = -2\tau_1$, $d_0 = \frac{\tau_2^2}{2\tau_1} - 2\tau_3$ e $n_0 = 2\tau_0 + 1$.
- Simplificação do sistema (mais detalhes no final).
- Inclusão do cálculo analítico do Jacobiano no Newton-Raphson: redução do tempo computacional.

Simplificação do sistema no caso Normal

Sistema original:

$$\begin{aligned} \frac{(2\tau_0 + 1)\tau_2^2}{2\tau_1\tau_2^2 - 8\tau_1^2\tau_3} - \frac{1}{2\tau_1} &= (q_1 + f1^2) \exp(f_2 + q_2/2) \\ -\frac{(2\tau_0 + 1)\tau_2}{\tau_2^2 - 4\tau_1\tau_3} &= f1 \exp(f_2 + q_2/2) \\ \frac{4\tau_1(\tau_0 + 1/2)}{\tau_2^2 - 4\tau_1\tau_3} &= \exp(f_2 + q_2/2) \\ \gamma(\tau_0 + 1/2) - \log\left(\frac{\tau_2^2}{4\tau_1 - \tau_3}\right) &= f_2 \end{aligned}$$

Observe que:

$$-\frac{(2\tau_0 + 1)\tau_2}{\tau_2^2 - 4\tau_1\tau_3} = -\frac{2\tau_2}{4\tau_1} \frac{4\tau_1(\tau_0 + 1/2)}{\tau_2^2 - 4\tau_1\tau_3}$$

Usando a equação 3, temos:

$$-\frac{(2\tau_0 + 1)\tau_2}{\tau_2^2 - 4\tau_1\tau_3} = -\frac{2\tau_2}{4\tau_1} \frac{4\tau_1(\tau_0 + 1/2)}{\tau_2^2 - 4\tau_1\tau_3} = -\frac{2\tau_2}{4\tau_1} \exp(f_2 + q_2/2) = f1 \exp(f_2 + q_2/2)$$

Daí:

$$-\frac{2\tau_2}{4\tau_1} = \mu_0 = f_1$$

Veja agora que:

$$\frac{(2\tau_0 + 1)\tau_2^2}{2\tau_1\tau_2^2 - 8\tau_1^2\tau_3} = \frac{-\tau_2}{2\tau_1} \frac{(2\tau_0 + 1)\tau_2}{\tau_2^2 - 4\tau_1\tau_3}$$

Usando a equação 2 e que $-\frac{\tau_2}{2\tau_1} = \mu_0 = f_1$, temos:

$$\frac{(2\tau_0 + 1)\tau_2^2}{2\tau_1\tau_2^2 - 8\tau_1^2\tau_3} = \frac{-\tau_2}{2\tau_1} \frac{(2\tau_0 + 1)\tau_2}{\tau_2^2 - 4\tau_1\tau_3} = f_1^2 \exp(f_2 + q_2/2)$$

Voltando à equação 1:

$$\frac{(2\tau_0 + 1)\tau_2^2}{2\tau_1\tau_2^2 - 8\tau_1^2\tau_3} - \frac{1}{2\tau_1} = f_1^2 \exp(f_2 + q_2/2) - \frac{1}{2\tau_1} = (q_1 + f_1^2) \exp(f_2 + q_2/2)$$

Logo:

$$-\frac{1}{2\tau_1} = (q_1 + f_1^2) \exp(f_2 + q_2/2) - f_1^2 \exp(f_2 + q_2/2) = q_1 \exp(f_2 + q_2/2)$$

$$\frac{1}{c_0} = q_1 \exp(f_2 + q_2/2)$$

$$c_0 = \frac{1}{q_1 \exp(f_2 + q_2/2)}$$

Assim, as duas primeiras equações do sistema possuem solução analítica e que não depende de n_0 e d_0 . Vamos agora para a equação 3. Usando que $\frac{n_0}{2} = \tau_0 + 1/2$ e que $\frac{4\tau_1}{\tau_2^2 - 4\tau_1\tau_3} = \frac{1}{\frac{\tau_2^2}{4\tau_1} - \tau_3} = \frac{1}{\frac{d_0}{2}}$:

$$\frac{4\tau_1(\tau_0 + 1/2)}{\tau_2^2 - 4\tau_1\tau_3} = \frac{n_0/2}{d_0/2} = \frac{n_0}{d_0} = \exp(f_2 + q_2/2)$$

Ademais, na equação 4, temos:

$$\gamma(\tau_0 + 1/2) - \log\left(\frac{\tau_2^2}{4\tau_1 - \tau_3}\right) = \gamma\left(\frac{n_0}{2}\right) - \log\left(\frac{d_0}{2}\right) = f_2$$

Com a equação 3, podemos escrever d_0 como função linear de n_0 , fazendo essa substituição na equação 4, obtemos:

$$\gamma\left(\frac{n_0}{2}\right) - \log\left(\frac{n_0}{2 \exp(f_2 + q_2/2)}\right) = f_2$$

Resolvemos o sistema acima usando Newton-Raphson e usando $x = \log(n_0)$ como argumento do sistema para garantir $n_0 > 0$:

$$\gamma\left(\frac{e^x}{2}\right) - x + \log(2) + f_2 + q_2/2 = f_2$$

Ou melhor:

$$\gamma\left(\frac{e^x}{2}\right) - x + \log(2) + q_2/2 = 0$$

É importante ressaltar que a solução deste sistema não depende de f_2 , ademais, o processo de resolução é bem estável numericamente, sendo resolvível mesmo para valores extremos de q_2 .

Uma vez obtido o valor de n_0 , temos o valor de d_0 através da relação:

$$d_0 = \frac{n_0}{\exp(f_2 + q_2/2)}$$

Problema: se $f_2 + q_2/2$ for muito grande, $\exp(f_2 + q_2/2)$ pode ser computacionalmente intratável, porém, para qualquer valor de q_2 , é possível fazer uma mudança de escala nos dados de maneira que $\exp(f_2 + q_2/2)$ se torne tratável, pois ao multiplicarmos os dados por uma constante c , obtemos:

$$f_2^* = f_2 - \log(c),$$

pois f_2 é a log precisão, ademais, q_2 não muda de valor, pois a variância não é afetada pela soma/subtração de constantes.